

Laboratorium 2 ze statystyki

Cele

- Celem zadań 1, 2 i 4 jest zastosowanie twierdzenia z wykładu mówiącego, że jeśli $\hat{\theta}$ jest ENW parametru θ a $g = g(\theta)$ funkcją parametru θ , to $g(\hat{\theta})$ jest ENW wielkości g i porównanie wyników z oczekiwaniami.
- W zadaniu 4 użyjemy wykresu kwantylowego do sprawdzenia czy rozkład danych jest normalny.
- Zadanie 5 to porównanie wyników eksperymentalnego wyznaczania ENW dla rozkładów: normalnego i Laplace'a.
- W zadaniu 6 sprawdzamy, jaki wpływ na szacowania ma rozmiar próby.

Każde z zadań zawiera krótkie podsumowanie.

Zadanie 1 - rozkład dwumianowy

Wielkość $P(X \leq 3)$ jest funkcją parametru p :

$$P(p) = \binom{5}{3}p^3(1-p)^{1-3} + \binom{5}{4}p^4(1-p)^{1-4} + \binom{5}{5}p^5(1-p)^{1-5}$$


stąd estymator największej wiarygodności P otrzymamy wyznaczając ENW p (dla tego rozkładu jest nim proporcja sukcesów) i przekazując otrzymaną wartość do funkcji $P(p)$.

Table 1: Średni błąd kwadratowy, wariancja i obciążenie estymatora największej wiarygodności P dla wybranych wartości parametru

| p | n | MSE | bias | var |
|-----|----|-----------|------------|-----------|
| 0.1 | 50 | 0.0082477 | -0.0906803 | 0.0003642 |
| 0.3 | 50 | 0.0198273 | -0.1353981 | 0.0008587 |
| 0.5 | 50 | 0.0035856 | -0.0008535 | 0.0010366 |
| 0.9 | 50 | 0.0082477 | 0.0906803 | 0.0003642 |

1. Estymowane wartości $P(X \leq 3)$ są bliskie prawdziwym teoretycznym wartościom, a MSE, obciążenie i wariancja małe - oznacza to, że wybrany sposób estymacji jest bardzo dobry.
2. Wykonując dodatkowe eksperymenty można zauważyć, że wartości MSE, obciążenia i wariancji są symetryczne względem $p = 0.5$.

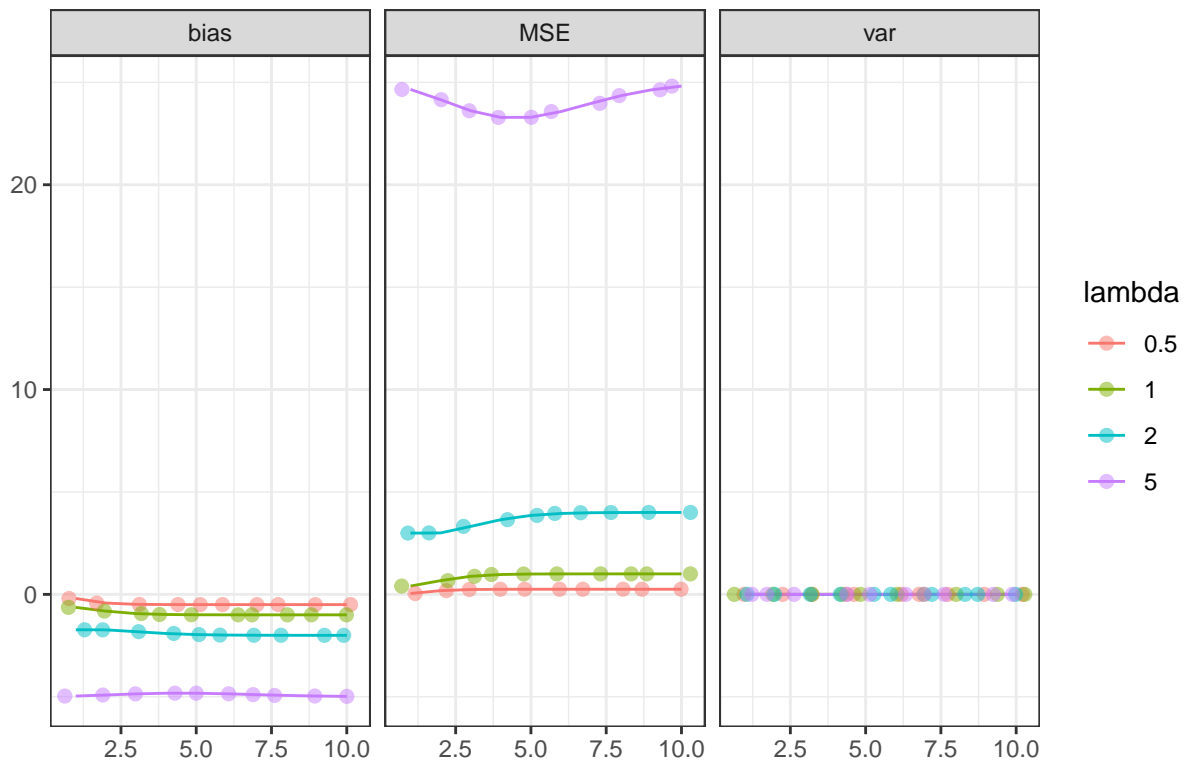
Wykres zależności błędów ENW wielkości $P(X \leq 3)$ od parametru p



Zadanie 2 - rozkład Poissona

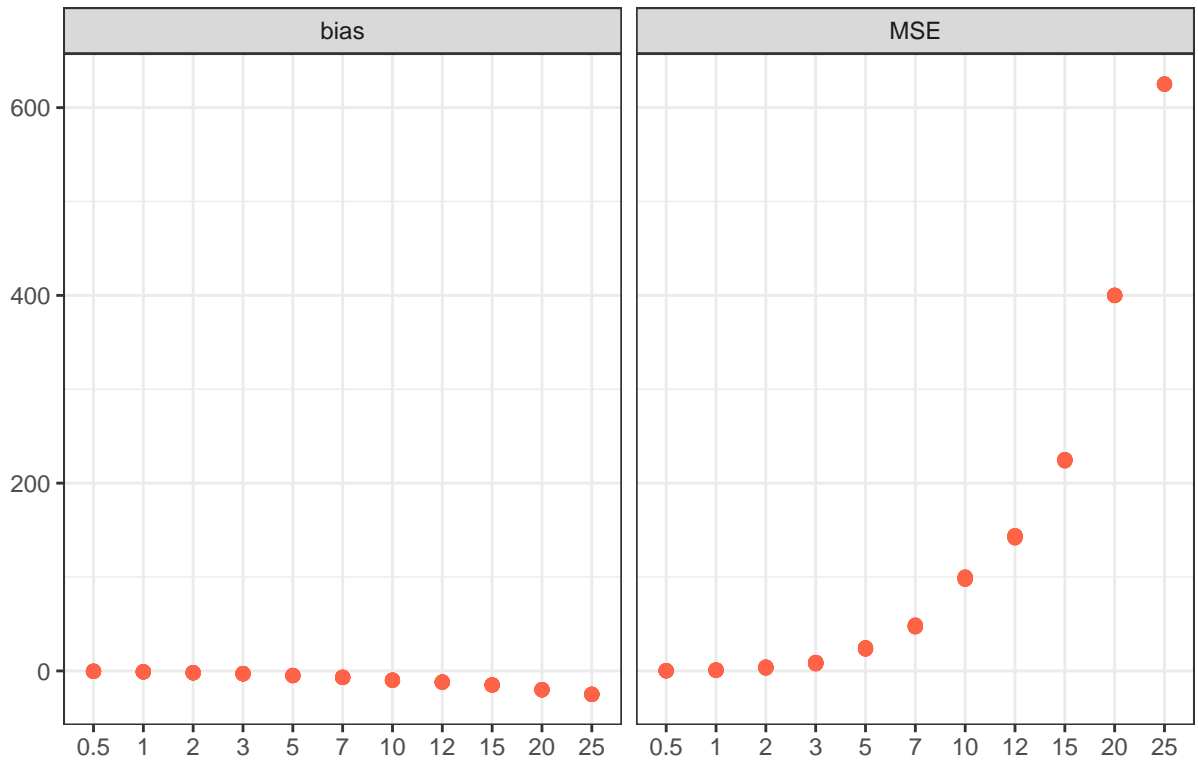
Estymatorem największej wiarygodności parametru λ jest średnia arytmetyczna. W celu wyznaczenia ENW $P(X = x)$, korzystamy z tego samego sposobu co w zadaniu 1.

Obciążenie, MSE i wariancja estymatora wartości $P(X = x)$ dla wybranych wartości



1. Wariancja jest niezależnie od λ praktycznie zerowa.
2. Obciążenie i bezwzględna wartość średniego błędu kwadratowego rosną wraz ze wzrostem λ , ale nie różnią się znacząco dla różnych wartości x . Przeprowadziłam dodatkowe eksperymenty i sprawdziłam jak wygląda zależność obciążenia i MSE od λ .

Wykres zależności obciążenia i MSE od lambda




Zadanie 4

Gdy $\beta = 1$, to: funkcja masy prawdopodobieństwa jest postaci $P(x|\theta) = \theta x^{\theta-1}$, informacja Fishera jest funkcją parametru θ : $I(\theta) = \frac{1}{\theta^2}$, a estymator największej wiarygodności θ można wyrazić zwartym wzorem: $\hat{\theta} = \frac{-n}{\sum \ln(x_i)}$. Analogicznie do poprzednich zadań $I(\hat{\theta}) = I(\hat{\theta})$.

W pierwszej części zadania estymujemy informację Fishera dla wartości θ uzyskanych dla 10000 różnych prób - na wykresie widać, że estymatory przyjmują wartości zbliżone do takich, jakich możnaby się spodziewać, tzn. że ich średnie wartości są odwrotnie proporcjonalne do λ^2 . Ponadto, większe wartości parametru skutkują większą wariancją ENW informacji.

Jakie warto ci przyjmuje ENW informacji Fishera

Wykresy pudełkowe dla wybranych warto ci parametru



W dalszej części za zapamiętaną wartość estymatora $I(\hat{\theta})$ przyjmijmy średnią arytmetyczną wyników - takie oszacowanie powinno mieć tym mniejsze znaczenie, im większa będzie wartość θ ze względu na mniejszy rozrzut estymatora. Uwagi :

1. prezentowane wyniki są obliczane dla innych prób losowych niż użyte wcześniej.
2. krzywa normalna naniesiona na histogramy rysowana jest z użyciem średniej i odchylenia standardowego liczonych dla wszystkich wartości Y (tzn. $\theta = 0.5, 1, 2, 5$). Nie robi to dużej różnicy, gdyż indywidualne wyniki są pbardzo podobne.


```
## `summarise()` ungrouping output (override with `.groups` argument)
```

Table 2: Porównanie średniej i wariancji Y dla różnych wartości parametru


| th | mean | sd |
|-----|-----------|----------|
| 0.5 | 0.1366671 | 1.054771 |
| 1 | 0.1363110 | 1.060381 |
| 2 | 0.1597466 | 1.063109 |
| 5 | 0.1691760 | 1.080923 |

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```

Histogramy g sto ci uzyskanych warto ci Y dla ró nych warto ci theta; n = 50



Wykresy kwanntylowo–kwanntylowe wielko ci Y dla ró nych theta
Czy rozkład jest normalny?



Wygląd wykresów pozwala stwierdzić, że rozkład wielkości Y jest bardzo bliski rozkładowi normalnemu i lekko skośny względem niego.

Zadanie 5

Table 3: Wyniki zadania 5c

| | MSE | bias | var |
|-----|-----------|------------|-----------|
| th1 | 0.0395111 | -0.0015393 | 0.0395126 |
| th2 | 0.0240074 | -0.0010795 | 0.0240087 |
| th3 | 2.7499850 | 0.0304426 | 2.7493332 |
| th4 | 0.0399686 | 0.1025496 | 0.0294551 |

Przypadku wszystkich testowanych wartości parametrów najlepszym estymatorem okazał się θ_2 , czyli mediana. Nie ma w tym nic dziwnego - poprzednio była nim średnia, która jest ENW parametru dla rozkładu normalnego, a mediana jest ENW parametru dla rozkładu Laplace'a.

Zadanie 6.1

Po wykonaniu eksperymentu dla $n = 20$ i $n = 100$ okazało się, że rozmiar próby nie ma wpływu na kształt wykresu przedstawionego w zadaniu 1. Dla jeszcze mniejszych prób można zaobserwować różnice, co można wyjaśnić tym, że $n = 20$ często przyjmuje się za minimalną do uzyskania zgodnych z teorią wyników liczebność próby.

Zadanie 6.2

Zmiana liczebności próby nie wpływa znacząco na zależności wariancji, średniego błędu kwadratowego i obciążenia od parametru, natomiast ich bezwzględne wartości maleją wraz ze wzrostem n .

Zadanie 6.4

Eksperymenty wykazały, że dla większej liczebności próby punkty na wykresie kwantylowo-kwantylowym leżą bliżej prostej, co oznacza że rozkład jest bardziej zbliżony do normalnego. Można to uzasadnić tym, że Y dąży w rozkładzie do rozkładu normalnego.

Zadanie 6.5

Wyniki dla $n = 100$ są zbliżone do wyników dla $n = 50$, z trochę mniejszymi wartościami błędów dla sensownych estymatorów. W przypadku $n = 20$ widać większą losowość - znów ma to związek ze zbyt małą do uzyskania zgodnych z teorią liczebnością.